

LASSO

Data visualization

川田恵介

東京大学

keisukekawata@iss.u-tokyo.ac.jp

2026-08-04

1 線形モデルへの機械学習の応用

1.1 機械学習

- 回帰木モデル以外にも、有力な機械学習の手法は多く存在する
- 代表例は、LASSO
 - ▶ OLS と同様に線形モデルを推定する手法

1.2 線形モデル VS 回帰木モデル


- 平均値を近似する方法
 - ▶ 回帰木モデル: サブグループ平均値で近似する
 - ▶ 線形モデル: β についての足し算モデルで近似する

$$\beta_0 + \beta_1 \times X_1 + \dots$$

1.3 復習: 理想の予測モデル

- 理想の予測モデルは、母平均
 - ▶ 無限大の事例数があれば、データ上の平均値が理想の予測モデル

1.4 例: 母平均




1.5 復習: データ


- 個人差がある限り、平均値から乖離する
 - ▶ 限られた事例から計算されるデータ上の平均も乖離する

1.6 例: データ

1.7 例: 母平均



1.8 例: データ上の平均




1.9 復習: OLS

- データ上の平均値を、線形モデルで近似する;

$$Y \simeq \beta_0 + \beta_1 \times D$$

1.10 例: OLS




1.11 モデルの複雑化


- 単純な線形モデルは、複雑な母平均から乖離する
 - “一直線”で、“曲線”は表現できない
- 線形モデルを複雑化することは容易
- 例: 高次項

$$\beta_0 + \beta_1 \times D + \beta_2 \times D^2 + \beta_3 \times D^3 + \dots$$

1.12 例: $\beta_0 + \beta_1 D + \beta_2 D^2$



1.13 例: $\beta_0 + \beta_1 D + \dots + \beta_6 D^6$




2 事例数


2.1 事例数の影響

- 複雑なモデルは、データ上への平均値への当てはまりが良い
- 事例数が増えると、データ上での平均値 $\simeq$ 母平均
 - ▶ 複雑なモデル $\simeq$ 母平均

2.2 例: $\beta_0 + \beta_1 D + \text{dots} + \beta_6 D^6$



2.3 例: $\beta_0 + \beta_1 D$



2.4 交差項

- X が複数存在する場合、掛け算をモデルに導入できる

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2$$

2.5 Takeaway

- 複雑なモデルを推定すれば、モデルはより柔軟にデータに適合する
 - ▶ よりデータ主導アプローチ
- 複雑なモデルは、母平均から大きく乖離したデータ上の平均値の特徴を捉えてしまう

3 LASSO

3.1 OLS の限界

- 良い予測モデルを推定するためには、適切な複雑性を持つモデルを研究者が設定する必要がある
 - ▶ 多くの応用で難しい

3.2 LASSO

- (二乗項や交差項を含む)複雑な線型モデル $g(X) = \beta_0 + \dots + \beta_L X_L$ を以下を最小化するように推定する

$$\text{平均二乗誤差} + \underbrace{\lambda}_{\text{TuningParameter} > 0} \times \underbrace{(|\beta_1| + \dots + |\beta_L|)}_{\text{複雑性の測定値}}$$

- 複雑性に”課税 (税率 λ) “することで、単純なモデル「 $g(X) = \beta_0 = Y$ の平均値」に近づける

3.3 実装例

```
lm(Price ~ poly(Size,2) + poly(Tenure,2) + Size:Tenure, data)
```

Call:

```
lm(formula = Price ~ poly(Size, 2) + poly(Tenure, 2) + Size:Tenure,
    data = data)
```

Coefficients:

(Intercept)	poly(Size, 2)1	poly(Size, 2)2	poly(Tenure, 2)1
64.50855	3710.84191	1168.83982	371.78073
poly(Tenure, 2)2	Size:Tenure		
423.80494	-0.02057		

```
hdm::rlasso(Price ~ poly(Size,2) + poly(Tenure,2) + Size:Tenure, data)
```

Call:

```
rlasso.formula(formula = Price ~ poly(Size, 2) + poly(Tenure,
2) + Size:Tenure, data = data)
```


Coefficients:

(Intercept)	poly(Size, 2)1	poly(Size, 2)2	poly(Tenure, 2)1
45.24	2753.65	1196.06	-913.88
poly(Tenure, 2)2	Size:Tenure		
399.30	0.00		

3.4 λ の選び方

- 推定された予測モデルと母平均の乖離を小さくするように設定したい
- いくつかの方法が提案
 - 赤池情報基準の利用 (gamlr)
 - 交差推定の利用 (glmnet)
 - 理論指標の利用 (hdm)
 - 詳細は CausalMLBook 第3章 参照

3.5 例




3.6 変数選択

- LASSO 法は、“データ主導の変数選択”を伴う手法であると強調される
 - ▶ 係数値 β が厳密に“0”となる変数が生じる
 - 該当する変数が、モデルから“除外された”と解釈できる
 - ▶ OLS では生じない

3.7 データ主導の問題点

- 推定されているモデルから除外されている $\neq$ Population OLS においても除外される
 - ▶ 限られた事例数に対処するために、“しょうがなく”単純化している
- LASSO や回帰木などの推定値については、信頼区間を計算するのが難しい
 - ▶ データ主導のモデル化のせいで、データの特徴と推定結果が複雑な関係性を持つため

3.8 例 $Price \sim 0 + District$



3.9 Takeaway

- データ主導の線型モデル推定
 - 二乗項や交差項により複雑化したモデルを、データ手動で単純化する
- 予測性能が改善する応用が存在する
 - 信頼区間が計算しにくく、母集団の特徴を推論する手法としては使いにくい
 - 例外は 100 % 近い予測性能を発揮するケースだが、市場/社会分析では望み薄

3.10 Reference

Bibliography