

調整後の比較

Data visualization

川田恵介

東京大学

keisukekawata@iss.u-tokyo.ac.jp

2026-08-04

1 比較

1.1 モデルの種類

- 予測が難しかったとしても, 記述 (全体的な特徴の把握) は可能
- 経済学では特に比較分析が重要
- 例: 平均取引価格の時系列変化
 - ▶ 2019 年から 2024 年にかけて, 平均取引価格はどのように変化したか?

1.2 復習: 比較

- 推定目標 = 母集団上で, 以下を最小化するモデル Y の平均値 $\hat{Y} = \beta_0 + \beta_1 D$
- β の数が少なければ, データ上で最小化すれば類似するモデル
 - ▶ 信頼区間も計算できる

1.3 例

```
library(tidyverse)

data <- nanoparquet::read_parquet("data.parquet")

model_simple <- estimatr::lm_robust(
  Price ~ 0 + year_2024, # ファクター変数に変換
  data
)

model_simple
```

	Estimate	Std. Error	t value	Pr(> t)	CI Lower	CI Upper	DF
year_2024	52.887	0.7685057	68.81797	0	51.38059	54.3934	11310

2 調整後の比較


2.1 市場分析

- “需要”が増大しても、価格は低下しうる
 - ▶ 平均価格: 異なる特徴を持つ物件の市場の集計値
 - “需要”増加に伴う供給変化は、市場によって異なる
 - “条件の悪い”物件の取引も活発化し、“単価”は低下する必要がある
 - ▶ 同じような特徴を持つ物件内で比較した方が、市場分析としては適切

2.2 例

```
fig <- data |>
  pivot_longer(
    cols = c(Size, Tenure)
  ) |>
  ggplot(
    aes(
      x = value,
      fill = factor(year_2024)
    )
  ) +
  geom_density(alpha = 0.5) +
  theme_bw() +
  facet_wrap(
    ~name,
    scales = "free_x",
    ncol = 1
  )
```


2.3 例



2.4 cobalt

- 多数の変数について、視覚的に比較できる

```
comparison <- cobalt::bal.tab(  
  year_2024 ~ Price + Size + Tenure + Distance,  
  data  
)  
  
cobalt::love.plot(comparison)
```



2.5 部分線型モデル

- 以下のモデルを推定する

$$Y \text{ の平均値} = E[Y \mid D, X] \simeq \underbrace{\beta_D \times D + f(X)}_{D, X \text{ のモデル}}$$

- β_D の値が推定上の関心 (Parameter of Interest, Estimand)
 - $\beta_D \simeq E[Y \mid D = 1, X] - E[Y \mid D = 0, X]$
- $f(X)$ は関心外


2.6 OLS による推定

- $f(X)$ を複雑なモデル ($\beta_0 + \beta_1 X_1 + \dots$) として定式化し, OLS で推定する

2.7 例

```
model <- estimatr::lm_robust(
  Price ~ year_2024 + poly(Size,2) + poly(Tenure,2) + poly(Distance,2) +
    District + (Size + Tenure + Distance + District)^2,
  data
)

dotwhisker::dwplot(
  list(Simple = model, Long = model_simple),
  vars_order = c("year_2024")
)
```



2.8 OLS の問題点

- X の数が増えると、推定モデルが非常に複雑になる
 - ▶ OLS ではうまく推定できなくなる
 - ▶ 信頼区間の計算も難しくなる
- LASSO の活用が有力

3 D と X の相関

3.1 D と X の相関

- 母平均の「正しくシンプルなモデル」を推定できない場合、 D と X の相関関係に注意が必要
- D と X 相関が強い場合、モデルの定式化は D のパラメタ (Population OLS の結果; 推定目標) やその推定結果に大きな影響を与える

3.2 数値例: Mac 格差

- 条件付き母平均:

$$E[Y \mid \text{Mac}, \text{Win}] = 0.8 \times \text{Mac} + \text{Win}$$

- Y : Excel スキル
 - ▶ Mac: Mac を 2 年以上利用した経験があれば 1、それ以外は 0

- ▶ Win: Win を 2 年以上利用した経験があれば 1、それ以外は 0
- 個別の $Y = \text{母平均} + \text{一様分布} (-5 \sim 5)$

3.3 数値例: 推定するモデル

- 以下の二つのモデルを比較する;
- $Long = \beta_0 + \beta_{Mac} \times Mac + \beta_{Win} \times Win$
 - ▶ $E[Y | Mac, Win]$ を極力近似する
- $Short = \beta_0 + \beta_{Mac} \times Mac$
 - ▶ $E[Y | Mac]$ に当てはまる

3.4 数値例: 相関構造


- 非現実的な想定

無相関	Mac=1	Mac=0
Win=1	.25	.25
Win=0	.25	.25


- より現実的 (?) な想定

逆相関	Mac=1	Mac=0
Win=1	.05	.45
Win=0	.45	.05


3.5 直感: 無相関




3.6 直感: 無相関




3.7 直感: 無相関




3.8 直感: 逆相関



3.9 直感: 逆相関



3.10 直感: 逆相関



3.11 直感

- Win の利用経験が同じであれば、Mac の利用経験と Excel スキルは正の相関

- Macの有無のみで単純比較すると、「Macの経験がない人は、Winの経験を持つ割合が高い」という相関構造の影響も含めた比較を行う
 - ▶ 「Mac未経験者(実は大半がwin経験者)の方が、Excelスキルが高い」という、“()”を無視すると、直感に反する推定結果が示されがち

3.12 まとめ

- D と X の相関が激しいと、モデルの定式化 (Long/Short) で、点推定値や信頼区間の分布が決定的に変化する
- 注意: 信頼区間は「事実上の推定目標」が対象
- 相関がなければ

$$\begin{aligned}
 \text{Shortにおける } \beta_D &= \underbrace{E[Y \mid D = 1] - E[Y \mid D = 0]}_{\text{事実上の推定目標}} \\
 &\equiv \underbrace{E[Y \mid D = 1, X] - E[Y \mid D = 0, X]}_{\text{本来の推定目標}} \\
 &\quad \text{相関があれば}
 \end{aligned}$$

4 2重選択

4.1 定義

- Double Machine Learning の一種
 - ▶ 「OLS のシンプルな拡張」として理解できる、DML の優れた出発点
- 共通アイデア: 機械学習による「下準備を行い」、OLS や平均値などで推定目標を推定する

4.2 Post selection

- アイディア: LASSO による変数選択のみを活用する
 1. LASSO によって、 X の中から“重要な変数”のみを選ぶ
 2. 重要な変数のみ線形モデルに導入して、OLS で推定する
- 不偏性や中心極限定理は回復する?

4.3 非推奨: Single selection

1. 「 X から Y を予測するモデルを推定した際に除外された変数」を除外する
- Y の予測において、特に重要そうな X が選択される
 - D と X の相関構造の情報が有効活用されないため、非推奨

4.4 推奨: 2重選択

1. 「 X から Y または D を予測するモデルを推定し、どちらからも除外された変数」を除外する
 - D と X の相関構造の情報を明示的に活用
 - 「重要な変数は X の一部であり、事例数に比べて十分少ない」という仮定のもとで
 - ▶ 「変数はデータから選択された」という事実を”無視し”、通常の OLS と同様の手順で信頼区間を近似計算できる

4.5 Single selection の問題点

- 「モデルに含む変数」がデータに依存するので、推定結果の複雑な事前分布が生じる
 - ▶ 特に「 Y との相関はそこそこだが、 D との相関が強い変数」を誤って脱落させてしまうリスクが、無視できないほど高い
- 注意点: 機械学習による変数選択は、「絶対に正しい」、と錯覚しないことが重要
 - ▶ データ次第であり、確率的に正しい

4.6 Mac 格差における直感

- Win と Mac の相関が強い場合、Win はモデルに加えるべき変数
- $Y \sim Win$ を LASSO で推定すると
 - ▶ Win は重要な予測変数ではなく、脱落しやすい!!!
 - 「Win の経験はあるが、Mac は無し」 VS 「Mac の経験はあるが、Win は無し」の比較であり、

4.7 2重選択の利点

- ダブルチェック (Y の予測にも、 D の予測にも役に立たない場合のみ除外する) を行う、
 - ▶ 変数選択の影響を、“十分な事例数があれば、無視できるくらい小さくする”、ことができる
 - あたかも「データを見る前(事前)にモデルを決めた OLS」のように、推論できる

4.8 2重選択の性質

- 十分な事例数があり、「Population OLS における D のパラメタに大きな影響を与える変数は、 X の中の一部」 (Approximate Sparsity; 近似的に疎)、が仮定できれば
 - ▶ 信頼区間が計算できる

4.9 引用

Bibliography